

Estimación de la OSNR en Sistemas WDM sin rejilla usando Mapas de Calor y Redes Neuronales Artificiales

Kevin David Martinez Zapata
 Universidad de Antioquia
 Facultad de Ingeniería
 Dpto. de Electrónica y de Telecomunicaciones
kevin.martinez1@udea.edu.co

Resumen—Se propuso una técnica de estimación del OSNR en un sistema 3×16GBd WDM sin rejilla basado en mapas de calor y ANNs, logrando un error inferior a 0.45 dB.

Keywords—Deep learning, WDM, OSNR, regression, machine learning, elastic optical networks.

I. Contexto

Debido a la creciente demanda de ancho de banda, garantizar la calidad del servicio en redes ópticas elásticas (EONs) es crucial. La relación señal-ruido óptico (OSNR) es fundamental para evaluar la calidad de la señal [1], pero su estimación en redes sin rejilla es desafiante debido a la dificultad de medir el ruido con analizadores ópticos convencionales ya que es muy similar a los efectos de la interferencia inter-canal sobre el diagrama de constelación, como se muestra en la Figura 1, donde algunos símbolos caen en otros grupos de símbolos diferentes al suyo en pequeñas ventanas de tiempo. Aunque se han propuesto métodos basados en aprendizaje automático para estimar el OSNR, estos se centran en bandas de guarda específicas.

Este trabajo presenta un nuevo método que estima el OSNR según el espaciamiento entre canales, incluyendo canales superpuestos, utilizando los diagramas de constelación de los símbolos recibidos y redes neuronales artificiales (ANN). El enfoque convierte los diagramas de fase (I) y cuadratura (Q) en

mapas de calor para distinguir entre interferencia inter-canal y ruido de emisión espontánea amplificado (ASE), evaluándose como regresor en un sistema WDM 16-QAM.




Fig. 1. Efectos de la ICI en un diagrama de constelación IQ modulado en 16-QAM [2].

II. Objeto de Estudio

El objetivo principal del aprendizaje automático en este estudio es estimar el valor de OSNR en EONs sin rejilla. Para lograr esto, se utilizarán ANNs entrenadas con mapas de calor generados a partir de los diagramas IQ de los símbolos recibidos. Estos mapas de calor servirán como entrada al modelo, permitiendo estimar con precisión el OSNR a pesar de las demás distorsiones que presenta el sistema.

III. Escenario Experimental

El conjunto de datos fue obtenido de un experimento de un sistema 3×16 GBd WDM sin rejilla basado en 3 láseres reconfigurables con un ancho de línea de 100 kHz para modificar la separación entre los canales. El

ruido es añadido antes del receptor, como se muestra en la Figura 2.

El conjunto de datos consta de 729 imágenes de 64×64 píxeles de $\sim 12k$ símbolos representados en mapas de calor con una separación de canal que varía desde los 15 hasta los 18 GHz en pasos de 0.5 GHz, incluyendo el caso de canal único, y valores de OSNR que varían desde los 14.3 hasta los 36.3 dB, como se muestra en la Figura 2. El peso total del conjunto de datos es de ~ 2.8 MB.




Fig. 2. Escenario experimental 3×16 GBd WDM 16-QAM [2].

IV. Métricas de Desempeño

Las métricas de desempeño usadas en este trabajo se dividen en métricas de machine learning y de negocio.

1. Métricas de machine learning

Dado que el objetivo de este estudio es estimar el valor de OSNR a partir de mapas de calor generados por los diagramas IQ de los símbolos recibidos, se emplearán las siguientes métricas de desempeño:

A. Raíz del error cuadrático medio

Esta métrica se utiliza para cuantificar la diferencia entre los valores predichos por el modelo y los valores reales de OSNR. Se calcula como:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (1)$$

Donde y_i son los valores reales, y \hat{y}_i son los valores predichos. El RMSE se expresa en decibelios (dB), lo que permite una interpretación directa en el contexto de la calidad de la señal.

B. Error absoluto medio

El MAE es una métrica utilizada para cuantificar la diferencia promedio entre los valores reales y los valores predichos de OSNR, sin tener en cuenta la dirección del error. Se calcula como:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2)$$

Donde y_i son los valores reales de OSNR en cada mapa de calor, y \hat{y}_i son los valores predichos por el modelo. El MAE se expresa en dB, lo que facilita la interpretación del error en términos de la calidad de la señal.

2. Métricas de negocio

La implementación de un modelo preciso para la estimación del OSNR en EONs tiene implicaciones directas en la calidad del servicio y la satisfacción del cliente. Las métricas de desempeño en este contexto pueden ser:

A. Reducción de costos operativos

Un modelo preciso de OSNR permite una mejor gestión de recursos en la red, optimizando la asignación de ancho de banda y reduciendo el costo asociado al sobredimensionamiento de infraestructura. La métrica puede expresarse en términos de porcentaje de ahorro en costos operativos (CO) respecto a configuraciones previas como la Ecuación (3).

$$\% M = \frac{(CO_{actual} - CO_{mejorado})}{CO_{actual}} \times 100 \quad (3)$$

B. Incremento en la eficiencia del servicio

La mejora en la estimación del OSNR puede traducirse en un aumento en la eficiencia del servicio, medida en términos de capacidad adicional gestionada sin comprometer la calidad. Esta métrica puede expresarse como el porcentaje de aumento en la capacidad total (CT) manejada en relación con las estimaciones de OSNR usando la ecuación (4) para medir la capacidad actual C_{actual} y mejorada del sistema $C_{mejorada}$.

$$C_i = B * \log_2(1 + OSNR_i) \quad (4)$$

Donde C es la capacidad del sistema en bit por segundo (bps) y B es el ancho de banda del canal en Hz. Posteriormente, se usa la ecuación (3) para calcular el porcentaje de mejora con respecto al sistema actual, reemplazando el CO por CT.

V. Referencias y Resultados Previos

El problema de la estimación de la OSNR se ha tratado usando diferentes enfoques como esquemas de monitorización conjunta [3] o redes neuronales profundas [4] logrando errores de 0.5 y 0.81 dB, respectivamente. Sin embargo, existen muchos otros métodos que se han usado para monitorear la OSNR en sistemas WDM como se muestra en la Figura 3 donde entre las categorías más conocidas se encuentran los métodos directos, indirectos y los avanzados. En este último es donde se centra la técnica presentada en este trabajo.

En este caso, se obtuvieron los resultados que se muestran en las Figuras 4(a) y 4(b), evidenciando que, en este caso, es necesario entrenar con todos los datos disponibles en el conjunto de datos [ver Fig. 4(a)], lo cual es una de las limitantes ya que no es posible obtener nuevos datos. Sin embargo, el

modelo de aprendizaje profundo logró un error inferior a 0.45 dB en validación [ver Fig. 4(b)].

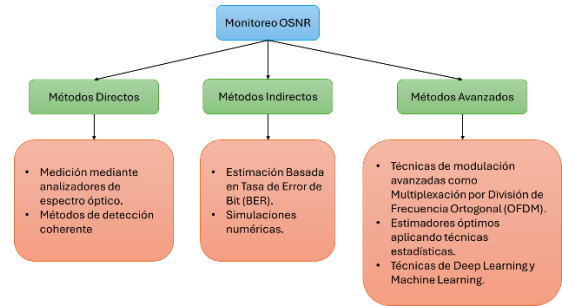


Fig. 3. Taxonomía de métodos usados para estimar la OSNR en sistemas WDM.




Fig. 4. Proceso de entrenamiento del modelo de aprendizaje profundo. a) curva de aprendizaje, y b) historia de entrenamiento.

Agradecimientos: Este trabajo fue posible gracias a los datos extraídos por el prof. Jhon James Granada Torres.

Disponibilidad de los datos: Los datos en los que se basan los resultados de este trabajo no pueden ser distribuidos públicamente, pero pueden obtenerse del autor con una solicitud previa razonable.

REFERENCIAS

- [1] J. Zhang *et al.*, "Fat-tree-based optical networks-on-chip with WDM: crosstalk noise exploiting," *IET Optoelectron.*, vol. 13, no. 2, pp. 85–93, 2019, doi: 10.1049/iet-opt.2018.5070.
- [2] K. D. M. Zapata and J. J. G. Torres, "Asymmetric demodulation using decision trees in gridless WDM systems," *Appl. Opt.*, vol. 63, no. 23, pp. 6253–6262, Aug. 2024, doi: 10.1364/AO.523447.
- [3] Z. Wang *et al.*, "Joint nonlinear optical signal-to-noise ratio estimation and modulation format identification based on constellation-points trajectory information and multitask 1DCNN for WDM systems," *Appl. Opt.*, vol. 61, no. 36, pp. 10744–10754, Dec. 2022, doi: 10.1364/AO.475792.
- [4] X. Xia, B. Li, H. Huang, Y. Tang, and W. Kong, "Research on OSNR monitoring technology based on deep neural network," in *International Conference on Mechatronics Engineering and Artificial Intelligence (MEAI 2022)*, SPIE, Feb. 2023, pp. 328–332. doi: 10.1117/12.2672152.